



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н. Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

НА ТЕМУ:

*«Метод повышения разрешения изображения по
нескольким кадрам»*

Студент ИУ7-13М
(Группа)

(Подпись, дата)

П. Ю. Сироткина
(И. О. Фамилия)

Руководитель НИР

(Подпись, дата)

М. В. Филиппов
(И. О. Фамилия)

2024 г.

РЕФЕРАТ

Расчетно-пояснительная записка 24 с., 12 рис., 1 табл., 20 источн., 1 прил.

Ключевые слова: цифровое изображение, суперрезолюция, суперразрешение, регуляризация, интерполяция, теория множеств, глубокое обучение, сверточные нейронные сети.

Объектом исследования является повышение разрешения изображения по нескольким кадрам низкого разрешения. Предметом исследования является набор цифровых изображений одного и того же объекта.

Целью работы являлась классификация известных методов повышения разрешения изображения по нескольким кадрам.

Для достижения поставленной цели были выполнены следующие задачи:

- проведен обзор существующих методов повышения разрешения изображения по нескольким кадрам;
- сформулированы критерии классификации и сравнения методов;
- классифицированы рассмотренные методы;
- проведен сравнительный анализ рассмотренных методов;
- на основе полученных теоретических сведений сделаны вывод об области применимости методов.

В результате было установлено, что выбор метода суперрезолюции зависит от конкретной задачи и имеющихся вычислительных и временных ресурсов. Методы на основе глубокого обучения часто дают наилучшие результаты, но они требуют большого объема данных и мощных вычислительных ресурсов для обучения сетей. Аналитические методы более вычислительно эффективны, но могут не давать такие высококачественные результаты, а также не учитывать структурные особенности изображений.

На основе проведенной классификации и сравнительного анализа для дальнейшей разработки было выбрано направление оптимизации сверточных нейронных сетей для повышения разрешения изображения по нескольким кадрам.

СОДЕРЖАНИЕ

РЕФЕРАТ	3
ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ	5
ВВЕДЕНИЕ	6
1 Аналитический раздел	7
1.1 Общие термины и понятия предметной области	7
1.2 Частотные методы	10
1.3 Пространственные методы	11
1.3.1 Регистрация – интерполяция – восстановление	11
1.3.2 Примеры – ориентированные методы	12
1.3.3 Реконструкция с регуляризацией	14
1.3.4 Методы резолуции на основе теории множеств	16
1.4 Методы на основе нейронных сетей	17
1.4.1 Оптимизация глубоких нейронных сетей	19
1.4.2 Проекция – аппроксимация – восстановление	19
2 Классификация методов повышения разрешения изображе-	20
ния	
2.1 Выявление классов рассмотренных методов суперрезолуции . .	20
2.2 Сравнительный анализ рассмотренных методов суперрезолуции	20
ЗАКЛЮЧЕНИЕ	22
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	23

ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

В настоящей расчетно-пояснительной записке применяют следующие сокращения и обозначения.

НР — изображение низкого разрешения.

ВР — изображение высокого разрешения.

СР — метод суперразрешения изображения.

СНС — сверточная нейронная сеть.

ВВЕДЕНИЕ

Среди способов восприятия человеком информации об окружающем мире посредством органов чувств зрение занимает особое место — с помощью глаз в среднем воспринимается до 80 % информации, поступающей из внешней среды [1]. Именно поэтому зрительные образы, часто запечатляемые снимками фотокамеры, играют важнейшую роль в нашей жизни.

Для многих задач, связанных с областью цифровой обработки сигналов, высокое разрешение изображения является ключевым аспектом, позволяющим проводить более качественный анализ и последующую обработку полученной информации. Изображение высокого разрешения содержит больше сведений о деталях, учет которых может быть критически важен во многих областях, таких как медицина, астрономия и многие другие.

В процессе формирования изображения качество может ухудшиться по многим причинам, таким как размытие, дефокусировка, движение камеры, шум, вибрации, малое количество сенсоров фотокамеры. Одним из способов решения рассматриваемой проблемы является использование более качественной техники, однако при таком подходе быстро достигается лимит стоимости, веса и размеров оборудования, что делает этот подход нецелесообразным с точки зрения использования ресурсов. Также понижение качества часто может быть связано с физическими ограничениями (например, при регистрации спутников).

В связи с этим существует широкое разнообразие методов повышения разрешения изображения, систематизация которых является актуальной задачей для систем фотосъемки.

1 Аналитический раздел

В данном разделе рассмотрены основные понятия рассматриваемой предметной области, а также проведен обзор существующих методов повышения разрешения изображения по нескольким кадрам.

1.1 Общие термины и понятия предметной области

Изображение, получаемое цифровой фотокамерой, можно определить как двумерную функцию $f(x, y)$, где x и y — пространственные координаты, принимающие конечное число дискретных значений. Значение функции f в некоторой точке, задаваемой парой координат (x, y) , является положительной скалярной величиной, называемой интенсивностью, или яркостью (уровнем серого) изображения в этой точке [2; 3].

В контексте данной работы под термином «кадр» понимается предоставляемое цифровое изображение низкого разрешения, используемое для синтеза изображения высокого разрешения. Каждый кадр является изображением одного и того же объекта, незначительно смещенного относительно других кадров из набора.

Чем больше количество точек (пикселей) на единицу площади изображения, тем выше его разрешение. Такие изображения предоставляют больше информации о деталях, учет которых может быть критически важен для различного рода задач (таких как медицина, наблюдения за спутниками, видеонаблюдение).

На рисунке 1.1 представлена модель наблюдения изображения низкого разрешения.

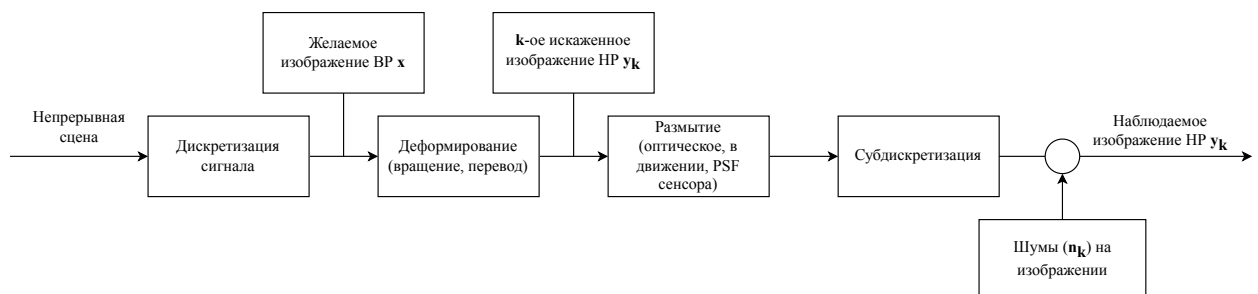


Рисунок 1.1 – Модель наблюдения изображения низкого разрешения

Задача повышения разрешения изображения по одному или нескольким кадрам низкого разрешения получила название суперразрешения (ан-

гл. *super resolution*) [4—6]. В общем случае эта задача является некорректной, т.к. в реальных задачах сведения об искажениях изображения заведомо неизвестны.

На рисунке 1.2 представлен пример фиксации положений движущегося объекта.




Рисунок 1.2 – Пример фиксации положений движущегося объекта

На рисунке 1.3 представлен пример набора кадров одного и того же объекта, регистрируемого фотосистемой.




Рисунок 1.3 – Пример набора кадров одного и того же объекта, регистрируемого фотосистемой

На рисунке 1.4 представлена связь между пикселями НР изображения и пикселями ВР изображения.




Рисунок 1.4 – Связь между пикселями НР изображения и пикселями ВР изображения

Как можно заметить, источником дополнительной информации для решения поставленной задачи являются субпиксельные сдвиги между кадрами набора.

Представим желаемое изображение ВР размером $N = L_1 N_1 \times L_2 N_2$ как вектор $x = [x_1, x_2, \dots, x_N]^T$. Параметры L_1 и L_2 представляют собой коэффициенты понижения дискретизации в наблюдении для горизонтального и вертикального направлений соответственно.

Таким образом, каждое изображение НР имеет размерность $M = N_1 \times N_2$. Аналогично представим каждое изображение НР в виде вектора $y_k = [y_{k_1}, y_{k_2}, \dots, y_{k_M}]^T$, где $k = \overline{1, p}$, p — размер входного набора.

Для получения изображения высокого разрешения x методом суперразрешения рассматривается следующая система уравнений [7]:

$$A_k x = y_k, \quad (1.1)$$

где оператор $A_k x$ в общем случае представляется в виде выражения (1.2).

$$A_k x = D \cdot B_k \cdot M_k \cdot x + n_k, \quad (1.2)$$

где:

- D — матрица движения фотосистемы (сдвиг, поворот и т.д.);
- B_k — матрица размытия (может быть вызвано оптической системой, относительным движением между фотосистемой и сценой, а также функцией рассеяния в датчике фотосистемы);
- M_k — матрица понижения размерности (генерирует изображение НР путем наложения, т.е. алиасинга).
- n_k — вектор шума.

Возможна более короткая форма записи:

$$A_k x = W_k \cdot x + n_k = y_k, \quad (1.3)$$

где матрица W_k размером $(N_1, N_2)^2 \times L_1 N_1 L_2 N_2$ представляет собой вклад пикселей изображения x в изображение y_k посредством размытия, движения и субдискретизации.

1.2 Частотные методы

Данная группа методов суперразрешения ориентирована на увеличение разрешения изображения посредством анализа частотных характеристик кадров. Классическим математическим аппаратом для подобных задач является Фурье – анализ.

Этот подход основывается на следующих принципах:

1. Свойство сдвига преобразования Фурье: $f(\widehat{x - x_0}) = e^{-i\omega x_0} \hat{f}(\omega)$.
2. Взаимосвязь между непрерывным преобразованием Фурье исходного изображения ВР и дискретным преобразованием Фурье наблюдаемых изображений НР.
3. Частотный диапазон изображения ограничен.

Пусть $x(t_1, t_2)$ — непрерывное изображение ВР, $X(w_1, w_2)$ — соответствующее ему непрерывное преобразование Фурье, $y_k[n_1, n_2]$ — k -ое изображение НР, $Y(\Omega_1, \Omega_2)$ — соответствующее ему дискретное преобразование Фурье.

Глобальные сдвиги, которые являются единственным движением, рассматриваемым в подходе частотной группы методов, порождают следующее уравнение для изображений НР:

$$x_k(t_1, t_2) = x(t_1 + \delta_{k_1}, t_2 + \delta_{k_2}), \quad (1.4)$$

где δ_{k_1} и δ_{k_2} — величины субпиксельных сдвигов между кадрами.

Согласно свойству сдвига преобразования Фурье:

$$X_k(w_1, w_2) = \exp[i \cdot 2\pi(\delta_{k_1} \cdot w_1 + \delta_{k_2} \cdot w_2)] \cdot X(w_1, w_2). \quad (1.5)$$

Смещенное изображение $x_k(t_1, t_2)$ дискретизируется с периодами T_1 и T_2 для создания наблюдаемого изображения НР $y_k[n_1, n_2]$ [8].

Таким образом, взаимосвязь между $X(w_1, w_2)$ и $Y(\Omega_1, \Omega_2)$ может быть описана в виде (1.6).

$$Y(\Omega_1, \Omega_2) = \frac{1}{T_1 \cdot T_2} \cdot \sum_{n_1=0}^{L_1-1} \sum_{n_2=0}^{L_2-1} X_k \cdot \left[\frac{2\pi}{T_1} \cdot \left(\frac{\Omega_1}{N_1} + n_1 \right), \frac{2\pi}{T_2} \cdot \left(\frac{\Omega_2}{N_2} + n_2 \right) \right]. \quad (1.6)$$

Учитывая, что функция X финитна, матрично – векторная форма уравнения может быть записана в виде (1.7).

$$Y = \Phi X. \quad (1.7)$$

1.3 Пространственные методы

1.3.1 Регистрация – интерполяция – восстановление

Линейный подход к решению задачи суперразрешения на основе интерполяции является наиболее тривиальным, однако в связи с этим имеет ряд существенных недостатков: возникновение алиасинга (эффект «лесенки»), размытия и эффекта Гиббса (проявляется в виде ореолов возле резких перепадов интенсивности).

Выделяют следующие этапы метода:

1. Непосредственно регистрация изображений НР и их последующее выравнивание до субпиксельной точности.
2. Интерполяция полученных изображений НР (например, с использованием метода ближайших соседей, интерполяции Ланцоша, линейной, биполярной, бикубической или гауссовской интерполяции).
3. Устранение размытия и помех (решение инверсной задачи) — получение изображения ВР.

На рисунке 1.5 представлен алгоритм суперразрешения на основе рассматриваемого подхода [9].




Рисунок 1.5 – Алгоритм суперразрешения на основе подхода регистрация – интерполяция – восстановление

Изображение представляется в виде функции, пиксели изображения — точки, в которых значение функции известно. Суть метода заключается в вычислении значения функции в промежуточных точках.

1.3.2 Примеро — ориентированные методы

Данная группа методов реализовывает подход, основанный на глубоком обучении [10]. Создается набор изображений (изображения ВР подвергаются деградации (см. рисунок 1.1) и формируется пара (ВР;НР)), который затем используется для анализа деталей, соответствующих отдельным областям цифрового изображения. Выявленные взаимосвязи используются для прогнозирования мелких деталей на других изображениях.

Рассмотрим алгоритм, предложенный в работе «Example – Based Super – Resolution» [11]. На рисунке 1.6 представлены изображения, иллюстрирующие суть алгоритма.




Рисунок 1.6 – Изображения, иллюстрирующие этапы алгоритма

На вход алгоритму подается исходное изображение НР 1.6.a и соответствующее ему изображение ВР 1.6.c. Изображение 1.6.b — результат интерполяции исходного изображения. Эта операция позволяет получить изображение нужного размера, но изображение по — прежнему не содержит достаточно сведений о деталях.

Следующий шаг — сохранить в базу данных каждый патч изображения ВР, соответствующий каждому патчу изображения НР (под патчем понимается небольшой участок изображения, обычно размером 5×5 или 7×7).

В виду того, что данная операция требует существенного количества памяти, изображения НР предварительно обрабатываются, чтобы устранить вариативность и сделать обучающие наборы максимально применимыми.

Предполагается, что высокочастотные компоненты патчей наиболее важны для предсказаний. В связи с этим к изображению 1.6.b применяется фильтр низких частот.

Также предполагается, что взаимосвязь между участками изображений с высоким и низким разрешением по существу не зависит от локального контраста изображения, в связи с чем применяется операция нормализации контраста.

На рисунке 1.7 представлен пример базы данных патчей согласно описанному выше методу.

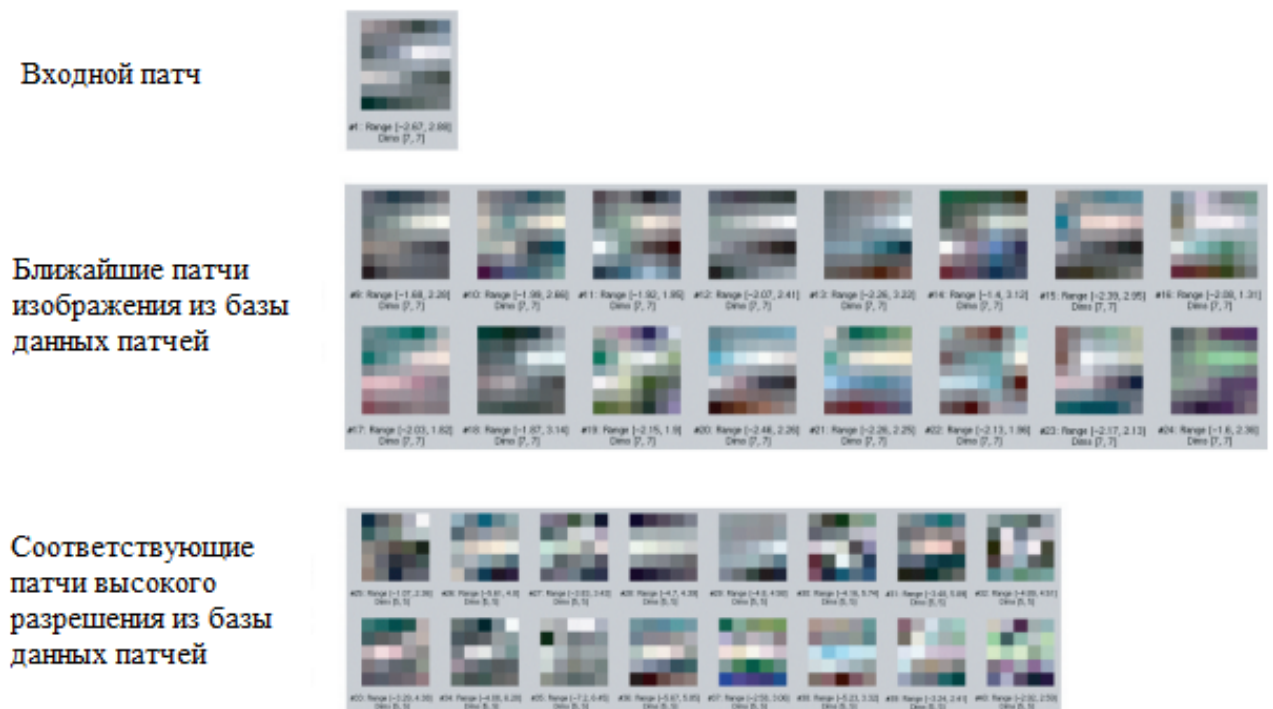


Рисунок 1.7 – Пример базы данных патчей

Таким образом, изображения 1.6.d и 1.6.e соответствуют изображениям 1.6.b и 1.6.c, подвергнутых описанным операциям. Полученная пара изображений используется для обучения.

Алгоритм суперразрешения осуществляется путем разбиения кадра на патчи и составления изображения ВР путем перебора соответствующих патчей в базе данных. На рисунке 1.8 представлен пример сравнения патчей.

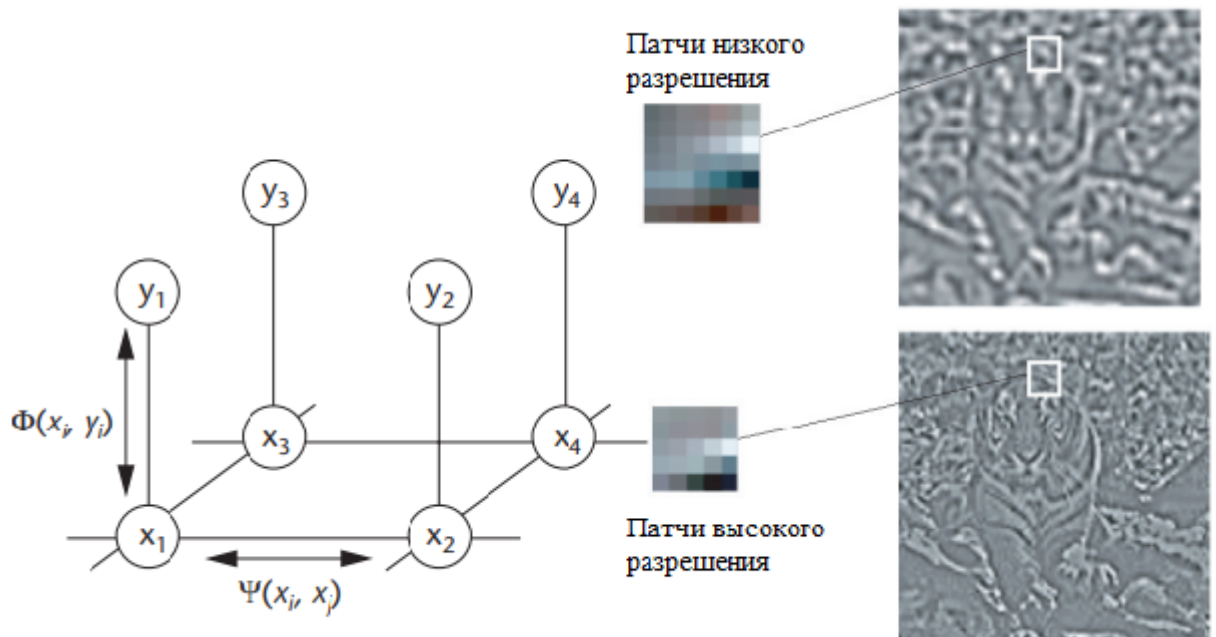


Рисунок 1.8 – Пример сравнения патчей

1.3.3 Реконструкция с регуляризацией

Задача реконструкции (решение обратной задачи) изображения ВР является некорректной в виду недостаточного количества информации о деталях и отсутствия априорной информации о функции размытия в общем случае. Методы регуляризации сводят некорректно поставленную задачу к корректной посредством введения дополнительных ограничений.

В данном разделе представлены детерминированные и стохастические (статистические) методы реконструкции.

Детерминированные регуляризационные методы

Оценив параметры регистрации, можно полностью уточнить модель наблюдения (1.2). Рассматриваемый подход решает обратную задачу, используя априорную информацию о решении, которая может быть использована для корректной постановки задачи.

Рассмотрим формулировку метода наименьших квадратов [12], выбрав x для минимизации Лангранжиана:

$$\sum_{k=1}^p \|y_k - W_k\|^2 + \alpha \|Cx\|^2, \quad (1.8)$$

где оператор C — фильтр верхних частот, $\|\cdot\|$ — l_2 — норма, α — параметр регуляризации (множитель Лангранжа), контролирующий компромисс между точностью данных. Чем больше значение α , тем более гладкое решение. Это может быть полезным, когда доступно небольшое количество изображений НР, а также когда точность информации на изображении низкая в виду зашумленности и ошибок регистрации, однако когда количество зображений НР достаточно большое и уровень шума в пределах нормы, то меньше значения α могут дать лучший результат.

Основные методы детерминированной итеративной регуляризации решают следующую задачу:

$$\left[\sum_{k=1}^p W_k^T W_k + \alpha C^T C \right] \hat{x} = \sum_{k=1}^p W_k^T y_k, \quad (1.9)$$

что приводит к формулировке следующей рекуррентной формулы для \hat{x} :

$$\hat{x}^{n+1} = \hat{x}^n + \beta \left[\sum_{k=1}^p W_k^T (y_k - W_k \hat{x}^n) - \alpha C^T C \hat{x}^n \right], \quad (1.10)$$

где β — параметр сходимости.

Стохастические регуляризационные методы

Данная группа методов основана на байесовской статистике и используется, когда можно установить апостериорную функцию плотности исходного изображения.

Оценка x с помощью метода максимального правдоподобия максимизирует апостериорную функцию плотности $P(x|y_k)$ относительно x :

$$x = \arg \max P(x|y_1, y_2, \dots, y_p). \quad (1.11)$$

Запишем задачу максимизации, применив логарифмирование, а также теорему Байеса к условной вероятности:

$$x = \arg \max \{ \ln P(y_1, y_2, \dots, y_p|x) + \ln P(x) \}. \quad (1.12)$$

Здесь и априорная модель изображения $P(x)$, и условная плотность $P(y_1, y_2, \dots, y_p|x)$ будут определяться априорной информацией об изображении ВР и статической информацией о шуме. Поскольку этот метод учитывает априорные ограничения, то предоставляется стабильная оценка изображения ВР.

Байесовская оценка также может быть осуществлена с использованием маркова случайного поля, описываемого приором Гиббса:

$$P(X = x) = \frac{1}{Z} \exp\{-U(x)\} = \frac{1}{Z} \exp\left\{-\sum_{i \in S} \phi_i(x)\right\}, \quad (1.13)$$

где Z — константа нормализации, $U(x)$ — энергетическая функция, $\phi_i(x)$ — функция производной изображения, которая зависит от значения пикселей, расположенных внутри S .

Главным преимуществом байесовской модели является использование предварительной модели изображения с сохранением краев изображения. В таком случае задача формулируется следующим образом [13]:

$$x = \arg \min \left[\sum_{k=1}^p \|y - W_k \cdot x\|^2 + \alpha \sum \phi(x) \right]. \quad (1.14)$$

1.3.4 Методы резолуции на основе теории множеств

Данная группа методов POCS (англ. *Projection Onto Convex Sets*) [14; 15] осуществляет альтернативный итеративный подход к учету априорных знаний для решения задачи реконструкции.

Согласно методу POCS, учет априорных знаний в решение можно интер-

претировать как наложение ограничения на то, чтобы решение было членом замкнутого выпуклого множества C_i , которое определяется как набор векторов, удовлетворяющих определенному свойству. Ограничение представляет собой предположительные сведения о гладкости, структуре, текстуре и других характеристиках изображения.

Если множества ограничений имеют непустое пересечение, то решение, принадлежащее множеству пересечений $C_s = \cap_{i=1}^m C_i$ (которое тоже является выпуклым множеством), можно найти, чередуя проекции на эти выпуклые множества.

После каждой итерации проекции обновляется текущее приближение к высокоразрешенному изображению. Этот процесс повторяется до тех пор, пока не достигнута сходимость или другие критерии остановки.

На рисунке 1.9 представлена иллюстрация метода суперразрешения на основе теории множеств.

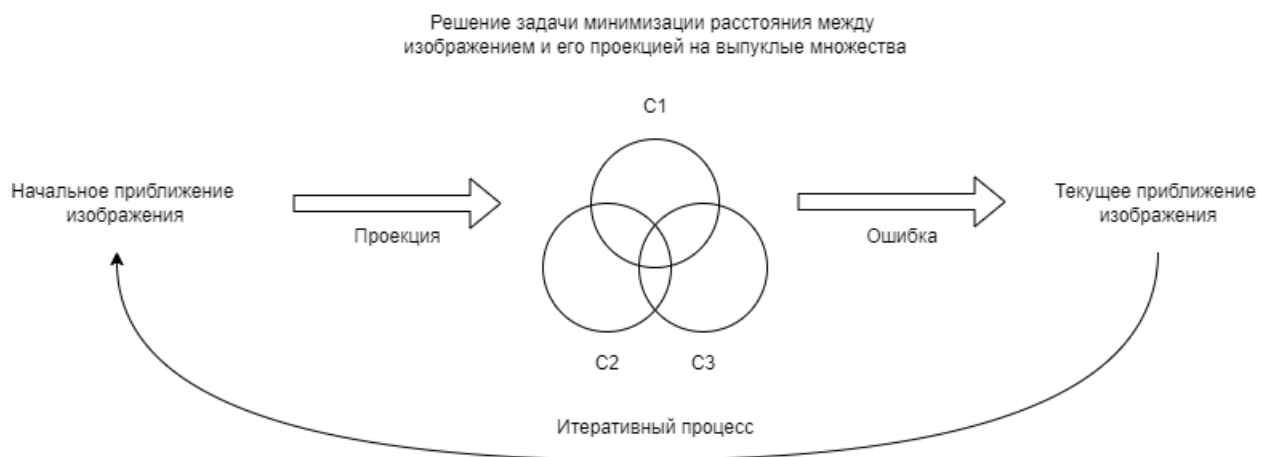


Рисунок 1.9 – Метод суперразрешения на основе теории множеств

1.4 Методы на основе нейронных сетей

Сверточные нейронные сети в области распознавания образов на изображениях и их классификации нашли широкое применение, что объясняется достаточно высоким качеством решения подобных задач.

Архитектура сети получила название в виду использования операции свертки. На рисунке 1.10 представлен пример выполнения операции. Для вычисления новых значений используется т.н. ядро свертки. На представленном примере ядром является матрица серого цвета размером 3×3 ячейки.




Рисунок 1.10 – Пример свертки цифрового изображения

На рисунке 1.11 представлена типовая архитектура сверточной нейронной сети.

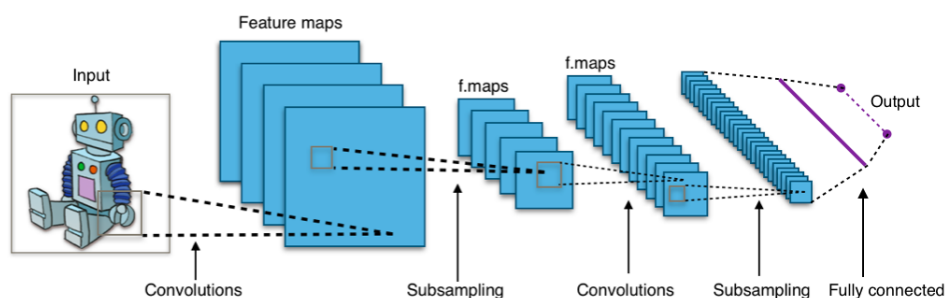


Рисунок 1.11 – Типовая архитектура сверточной нейронной сети

Как можно увидеть, СНС состоит из 3 типов слоев [16—18]:

1. Слой свертки — основной блок СНС, производящий свертку входной матрицы с ядром свертки. Количество ядер равно количеству карт признаков, выделяемых на изображении.
2. Слой пуллинга, или субдескритизация — данный слой принимает результат свертки предыдущего слоя в вид матрицы и сжимает данную матрицу с целью выделения низкоуровневых признаков.
3. Полносвязный слой — на данный слой подается одномерный вектор от стоящего перед ним слоя, причем данный вектор получен из матрицы путем записи ее элементов построчно в одну строку.

1.4.1 Оптимизация глубоких нейронных сетей

Одна из ключевых задач в тренировке глубоких нейронных сетей — оптимизация их параметров. Вследствие большого совокупного числа параметров на всех слоях нейронной сети применение методов второго порядка (таких как BFGS, SR1 и других квазиньютоновских методов) крайне затруднительно, а методы нулевого порядка в большинстве случаев не позволяют найти качественное решение за приемлемое время.

По этой причине для оптимизации глубоких и в том числе сверточных нейронных сетей, наиболее распространены методы первого порядка, требующие лишь знания градиента сети как функции от ее параметров. Сперва в качестве параметров алгоритма оптимизации глубоких нейронных сетей использовался градиентный спуск. Впоследствии было продемонстрировано, что градиентный спуск хоть и не требователен к вычислительным ресурсам, но значительно уступает многим методам первого порядка в скорости сходимости.

1.4.2 Проекция – аппроксимация – восстановление

Исходя из приведенных выше соображений, были разработаны методы, основанные на подходе проекции-аппроксимации-восстановления [19; 20].

Под подходом проекции–аппроксимации–восстановления понимается следующая процедура (далее обозначаемая акронимом ПАВ):

1. Проекция: проекция нескольких последних точек из оригинального пространства в пространство меньшей размерности посредством умножения на специальным образом построенную прямоугольную матрицу с ортонормальными строками.
2. Аппроксимация: построение квадратичного полинома, аппроксимирующего полученные проекции точек и соответствующие им значения целевой функции.
3. Восстановление: аппроксимация параметров целевой функции (например, Гессiana, точки минимума) в оригинальном пространстве на основе полученного полинома в пространстве меньшей размерности и прямоугольной матрицы из первого пункта.

2 Классификация методов повышения разрешения изображения

2.1 Выявление классов рассмотренных методов суперразрешения

На рисунке 2.1 представлены критерии, согласно которым можно классифицировать рассматриваемые методы повышения разрешения изображения.

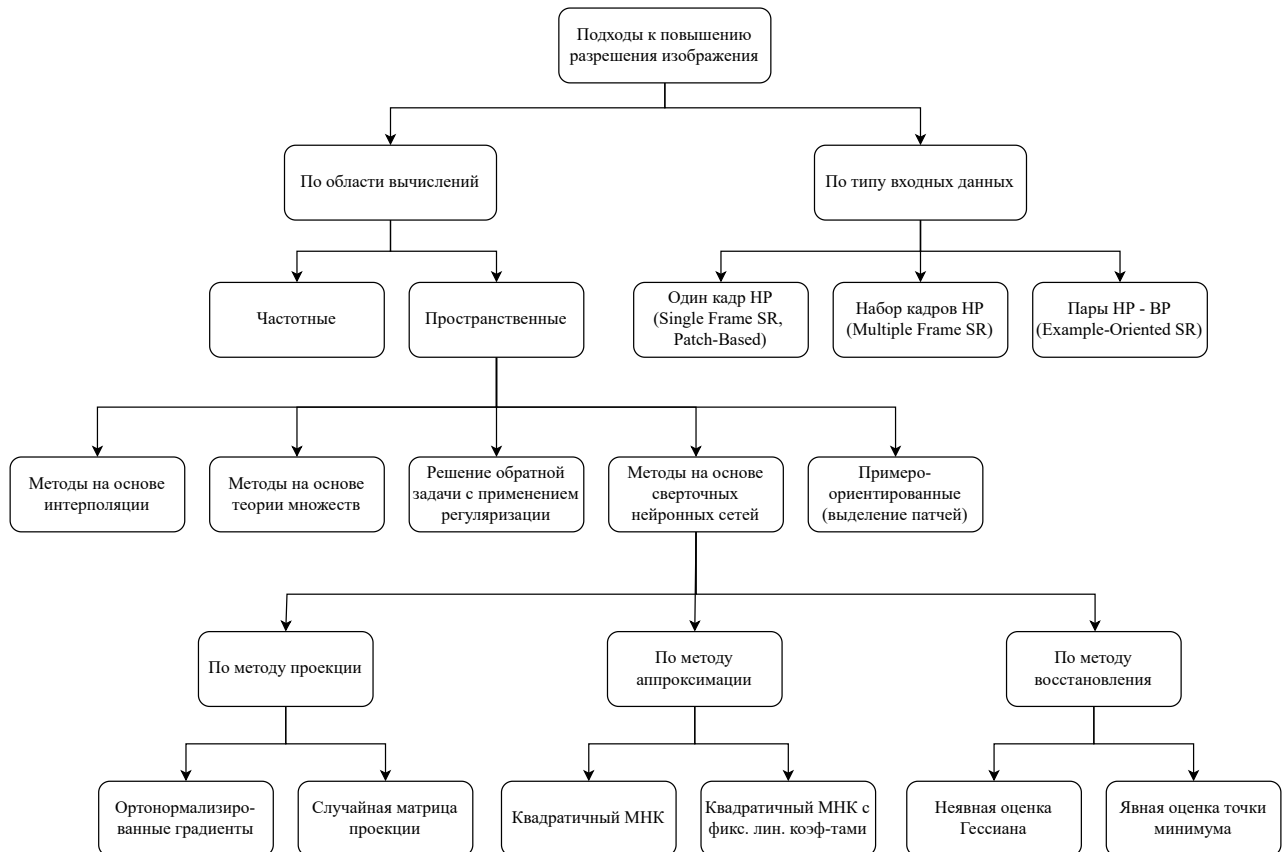


Рисунок 2.1 – Классификация подходов повышения разрешения изображения

2.2 Сравнительный анализ рассмотренных методов суперразрешения

При сравнительном анализе методов повышения разрешения изображения были выделены следующие критерии: вычислительная сложность метода, качество обработки и необходимость пост – или предобработки.

В таблице 2.1 представлен сравнительный анализ рассмотренных методов.

Таблица 2.1 – Сравнительный анализ рассмотренных методов

Метод	Критерий		
	Вычислит. сложность	Качество обработки	Необходимость пост- или предобработки
Частотные методы	Низкая	Низкое	Нет
Интерполяционные методы	Низкая	Очень низкое	Нет
Методы теории множеств	Средняя	Низкое	Да
Регуляризация	Средняя	Среднее	Нет
Выделение патчей	Очень высокая	Высокое	Да
СНС	Высокая	Очень высокое	Да

ЗАКЛЮЧЕНИЕ

В данной работе была рассмотрена задача повышения разрешения изображения по нескольким кадрам (задача суперразрешения).

Для достижения поставленной цели были рассмотрены существующие методы, а также проведены классификация и сравнительный анализ методов.

Были рассмотрены следующие группы методов: частотные методы, методы на основе интерполяции, методы на основе теории множеств, методы на основе решения обратной задачи с применением регуляризации, примеро – ориентированные методы, методы с использованием сверточных нейронных сетей.

Выбор метода суперразрешения зависит от конкретной задачи и имеющихся вычислительных и временных ресурсов. Методы на основе глубокого обучения часто дают наилучшие результаты, но они требуют большого объема данных и мощных вычислительных ресурсов для обучения сетей. Аналитические методы более вычислительно эффективны, но могут не давать такие высококачественные результаты, а также не учитывать структурные особенности изображений.

На основе проведенной классификации и сравнительного анализа для дальнейшей разработки было выбрано направление оптимизации сверточных нейронных сетей для повышения разрешения изображения по нескольким кадрам, т.к. в рамках поставленной задачи ключевым фактором является качество получаемого результата, другие же факторы (вычислительная сложность, необходимость пост – или предобработки) являются второстепенными.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Раков Д. Л. Морфологический анализ и синтез невозможных объектов //IMPART-2014. Невозможные объекты и оптические иллюзии в современном искусстве и дизайне (Традиционные и компьютерные технологии). – 2014. – С. 16-19.
2. Гришенцев А. Ю., Коробейников А. Г. Методы и модели цифровой обработки изображений. – 2014.
3. Гонсалес Р., Вудс Р. Цифровая обработка изображений. – Litres, 2022.
4. Manaila F., Boiangiu C. A., Bucur I. Super resolution from multiple low resolution images //Journal Of Information Systems Operations Management. – 2014. – С. 1.
5. Glasner D., Bagon S., Irani M. Super-resolution from a single image //2009 IEEE 12th international conference on computer vision. – IEEE, 2009. – С. 349-356.
6. Farsiu S. et al. Advances and challenges in super-resolution //International Journal of Imaging Systems and Technology. – 2004. – Т. 14. – №. 2. – С. 47-57.
7. Насонов А. В., Крылов А. С. Быстрое суперразрешение изображений с использованием взвешенной медианной фильтрации //Труды. – 2010. – С. 101-104.
8. Park S. C., Park M. K., Kang M. G. Super-resolution image reconstruction: a technical overview //IEEE signal processing magazine. – 2003. – Т. 20. – №. 3. – С. 21-36.
9. Кокошкин А. В. и др. Оценка ошибок синтеза изображений с суперразрешением на основе использования нескольких кадров //Компьютерная оптика. – 2017. – Т. 41. – №. 5. – С. 701-711.
10. Wang Q., Tang X., Shum H. Patch based blind image super resolution //Tenth IEEE International Conference on Computer Vision (ICCV'05) Volume 1. – IEEE, 2005. – Т. 1. – С. 709-716.

11. Freeman W. T., Jones T. R., Pasztor E. C. Example-based super-resolution //IEEE Computer graphics and Applications. – 2002. – Т. 22. – №. 2. – С. 56-65.
12. Katsaggelos A. K. Digital image restoration. – Springer Publishing Company, Incorporated, 2012.
13. Elad M., Feuer A. Restoration of a single superresolution image from several blurred, noisy, and undersampled measured images //IEEE transactions on image processing. – 1997. – Т. 6. – №. 12. – С. 1646-1658.
14. Fan C. et al. POCS Super-resolution sequence image reconstruction based on improvement approach of Keren registration method //Sixth International Conference on Intelligent Systems Design and Applications. – IEEE, 2006. – Т. 2. – С. 333-337.
15. Stark H., Oskoui P. High-resolution image recovery from image-plane arrays, using convex projections //JOSA A. – 1989. – Т. 6. – №. 11. – С. 1715-1726.
16. Бредихин А. И. Алгоритмы обучения сверточных нейронных сетей //-Вестник Югорского государственного университета. – 2019. – №. 1 (52). – С. 41-54.
17. Umehara K., Ota J., Ishida T. Application of super-resolution convolutional neural network for enhancing image resolution in chest CT //Journal of digital imaging. – 2018. – Т. 31. – С. 441-450.
18. Dong C. et al. Learning a deep convolutional network for image super-resolution //Computer Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part IV 13. – Springer International Publishing, 2014. – С. 184-199.
19. Senov A. Projective approximation based quasi-Newton methods// In: Proc. of International Workshop on Machine Learning, Optimization, and Big Data. 2017. P. 29–40.
20. Сенов А. А. Глубокое обучение в задаче реконструкции суперразрешения изображений //Стохастическая оптимизация в информатике. – 2017. – Т. 13. – №. 2. – С. 38-57.